


Сколько GPU у OpenAI и Anthropic и как они делятся между обучением и инференсом

Данные актуальны на 28 августа 2026 · компании не раскрывают точные цифры — везде оценки, диапазоны показывают неопределённость

Размер парка (оценки третьих сторон)



Train vs Inference — оценки отрасли

Frontier labs в целом (Epoch AI / industry model)



Anthropic, оценка расходов на compute (1 источник — Lambda Finance, агрегирует SemiAnalysis/AWS/GCP; низкая достоверность)



■ training ■ Inference ■ research (Anthropic-оценка)

Вывод:

OpenAI, по собственным заявлениям и оценкам трекеров, оперирует ~1-1.4 млн GPU (~5.7 млн H100-экв.); Anthropic не раскрывает парк GPU/TPU напрямую, но законтрактовала мощность, эквивалентную ~1.4-6.4 млн ускорителей к 2027 г. Доля обучения в compute у обеих компаний, по независимым оценкам, сегодня выше доли инференса (~60-70% vs ~30-40%), но, по прогнозам, будет снижаться к 2027-2028.

Источники: OpenAI/Altman (X, июль 2025); flopper.io datacenter tracker (не офиц.); Anthropic/Google press releases (окт. 2025, апр. 2026); TradingKey (конверсия ГВт→GPU); Epoch AI (arXiv 2504.16138); Lambda Finance (агрегатор, вторичный источник для Anthropic split).

С какой маржой Sail Research продаёт GLM 5.2

Цены — docs.sailresearch.com/pricing, 28 авг 2026 · маржа — оценка по bottom-up GPU-TCO модели (не по раскрытым данным Sail Research)

Цены GLM-5.2 (Sail), \$/1M ток.

Tier	In	Cache	Out
Default	\$0.80	\$0.16	\$3.00
Balanced	\$0.50	\$0.12	\$2.50
Flex	\$0.40	\$0.08	\$1.80

Кто такой Sail Research

80M(seed + A)@450M valuation,


Kleiner Perkins / Sequoia, июнь 2026

Позиционирование: throughput-over-latency инфра для агентов

Собственная заявка (PR компании):

«fully utilizes every computer in our fleet» + «до 10× дешевле конкурентов» — т.е. заявляют высокую загрузку GPU по дизайну

Сверка цены: кто сколько берёт



Модель: 744B всего / ~40B активных на токен (MoE), FP8 на узле 8×H200 (recipes.vllm.ai/zai-org/GLM-5.2) · Себестоимость: FLOPs/ток. ≈ 2×активные_парам., cost = GPU-часы × \$/GPU-час × MFU⁻¹ × overhead

Три сценария различаются по MFU (15–40%), цене GPU-часа (\$2–5) и overhead-множителю (1.5×–5×) — раскладка допущений в notebook.

Вывод:

Даже в базовом сценарии маржа по всем тарифам положительная (~65–79%); в минус модель уходит только при совпадении худших предположений сразу по трём параметрам. Sail сама заявляет высокую загрузку фермы и специализированные inference-движки — это довод в пользу Base/Bull, а не Bear. Цена Sail (\$3.00) на ~30% ниже официальной цены Z.ai (\$4.40) за output, но выше минимальной рыночной (\$1.56) — конкурентный reseller-прайсинг, не демпинг.

